Travaux pratiques progressifs

Big Data, Hadoop et applications Python

Projet fil conducteur pour huit groupes

Dr. Sena Apeke

Table des matières

1 Principe pédagogique **2**

2 Jeu de données fil conducteur **2**

2.1 Dictionnaire des variables 2

3 Règle de transmission entre groupes **3**

4 TP Groupe 1 – Fondamentaux du Big Data et Hadoop **3**

5 TP Groupe 2 – HDFS et Data Lake **3**

6 TP Groupe 3 – Conception MapReduce **4**

7 TP Groupe 4 – Hadoop Streaming avec Python **5**

8 TP Groupe 5 – YARN, monitoring et performances **5**

9 TP Groupe 6 – Hive et Data Warehouse distribué **6**

10 TP Groupe 7 – Spark et PySpark **7**

11 TP Groupe 8 – Pipeline Big Data et Machine Learning **7**

12 Livrable collectif final **8**

13 Évaluation proposée **8**

14 Consigne importante **8**

1 Principe pédagogique

Les huit groupes travaillent sur un même cas d'étude : l'analyse Big Data des ventes d'une chaîne commerciale multi-sites. Le travail est cumulatif : chaque groupe reprend les résultats techniques du groupe précédent, les valide, les enrichit et transmet un livrable exploitable au groupe suivant.

L'objectif final est de construire progressivement la chaîne :

Données → HDFS → MapReduce → Hadoop Streaming → YARN → Hive → PySpark → Machine Learning

2 Jeu de données fil conducteur

Le jeu de données représente des transactions commerciales réalisées dans plusieurs villes du Togo. Trois volumes sont prévus :

- `transactions_small.csv` : 10 000 lignes, tests locaux ;
- `transactions_medium.csv` : 500 000 lignes, développement et validation ;
- `transactions_big.csv.gz` : 5 000 000 lignes, expérimentation Big Data.

2.1 Dictionnaire des variables

Variable	Description
transaction_id	Identifiant unique de la transaction.
datetime	Date et heure de la transaction.
client_id	Identifiant du client.
ville	Ville du magasin.
magasin_id	Identifiant du point de vente.
categorie	Catégorie commerciale du produit.
produit	Produit acheté.
quantite	Nombre d'unités achetées.
prix_unitaire	Prix unitaire en FCFA.
remise	Taux de remise appliqué, entre 0 et 0,30.
mode_paiement	Espèces, Mobile Money, carte ou virement.
age_client	Âge du client.
type_client	Particulier, professionnel ou administration.
stock_avant	Stock disponible avant la transaction.
stock_apres	Stock restant après la transaction.
promotion	Indicateur 0/1 de promotion.
jour_semaine	Jour de la semaine.
livraison	Indicateur 0/1 de livraison.
montant	Montant net : quantité × prix unitaire $\times(1 - \text{remise})$.

3 Règle de transmission entre groupes

Chaque groupe doit commencer par vérifier les livrables du groupe précédent. Il est interdit de reconstruire silencieusement une sortie manquante : toute correction doit être documentée. Chaque groupe dépose ses résultats dans un répertoire commun et rédige un fichier `README.md` indiquant les commandes utilisées, les entrées, les sorties et les éventuelles anomalies.

4 TP Groupe 1 – Fondamentaux du Big Data et Hadoop

Objectif

Caractériser le jeu de données, établir une référence de traitement centralisé et mettre en place l'environnement Hadoop.

Travail demandé

1. Examiner `transactions_small.csv` avec Python/Pandas.
2. Identifier les types, valeurs manquantes, doublons, cardinalités et statistiques de base.
3. Calculer le chiffre d'affaires total et par ville avec Pandas.
4. Mesurer le temps d'exécution sur les jeux small et medium.
5. Installer/configurer Hadoop en mode pseudo-distribué.
6. Vérifier les services avec `jps`.
7. Créer `/data` dans HDFS et y charger le petit fichier.
8. Produire un schéma NameNode–DataNode–YARN.

Livrables transmis au Groupe 2

`benchmark_python.csv`, notebook/script Python, rapport de diagnostic, capture des services Hadoop et dataset validé.

5 TP Groupe 2 – HDFS et Data Lake

Objectif

Organiser les données dans HDFS et étudier blocs, réplication, capacité et résilience.

Travail demandé

Créer :

```
/datalake/
   raw/
      transactions/
   processed/
   results/
      mapreduce/
      hive/
      spark/
      ml/
```

Charger les datasets, utiliser `hdfs dfs -ls`, `-du -h`, `hdfs fsck`, étudier les blocs et facteurs de réplication. Pour un fichier de taille F et un bloc de taille B, vérifier :

$$N_{\text{blocs}} = \left\lceil \frac{F}{B} \right\rceil .$$

Comparer taille logique et occupation avec réplication.

Livrables transmis au Groupe 3

Data Lake opérationnel, chemins HDFS définitifs, tableau des blocs et réplications, rapport de stockage.

6 TP Groupe 3 – Conception MapReduce

Objectif

Transformer des analyses commerciales séquentielles en traitements MapReduce.

Travail demandé

Concevoir les couples clé–valeur et simuler localement :

1. nombre de transactions par ville ;
2. chiffre d'affaires par ville :
$$CA_v = \sum_{i \in v} q_i p_i (1 - r_i);$$
3. quantité vendue par produit ;
4. chiffre d'affaires par catégorie ;
5. nombre de transactions par mode de paiement.

Pour chaque problème, représenter explicitement Map, Shuffle/Sort et Reduce.

Livrables transmis au Groupe 4

Pseudo-code, scripts Python locaux, résultats de référence CSV et schémas clé–valeur.

7 TP Groupe 4 – Hadoop Streaming avec Python

Objectif

Implémenter sur Hadoop les algorithmes conçus par le Groupe 3.

Travail demandé

Écrire `mapper.py` et `reducer.py`, tester avec des pipes Unix puis exécuter les jobs avec Hadoop Streaming. Les sorties doivent être placées dans `/datalake/results/mapreduce/`. Réaliser au minimum trois jobs.

Comparer les résultats distribués aux résultats de référence du Groupe 3 et mesurer : temps total, volume d'entrée, volume de sortie et nombre de tâches.

Livrables transmis au Groupe 5

Mappers, reducers, scripts de lancement, sorties HDFS et tableau de performances.

8 TP Groupe 5 – YARN, monitoring et performances

Objectif

Analyser comment Hadoop affecte CPU et mémoire et expliquer les performances observées.

Travail demandé

Relancer les jobs du Groupe 4, suivre ResourceManager, NodeManager, ApplicationMaster et containers. Récupérer les logs YARN. Faire varier les ressources et les volumes small/medium/big. Calculer, lorsque pertinent :

$$S_p = \frac{T_1}{T_p}, \qquad E_p = \frac{S_p}{p}.$$

Identifier temps d'initialisation, I/O, shuffle et éventuels goulets d'étranglement.

Livrables transmis au Groupe 6

Configuration retenue, logs utiles, `benchmark_yarn.csv`, graphiques et interprétation de la scalabilité.

9 TP Groupe 6 – Hive et Data Warehouse distribué

Objectif

Construire une couche analytique SQL au-dessus des données HDFS.

Travail demandé

Créer une table externe Hive, puis une organisation partitionnée pertinente. Écrire des requêtes pour :

1. CA mensuel et annuel ;
2. CA et panier moyen par ville ;
3. Top 10 produits ;
4. ventes par catégorie et mode de paiement ;
5. impact des promotions ;
6. activité par jour de semaine ;
7. comparaison avec les résultats MapReduce.

```
CREATE EXTERNAL TABLE transactions (
 transaction_id STRING,
 datetime STRING,
 client_id STRING,
 ville STRING,
 magasin_id STRING,
 categorie STRING,
 produit STRING,
 quantite INT,
 prix_unitaire DOUBLE,
 remise DOUBLE,
 mode_paiement STRING,
 age_client INT,
 type_client STRING,
 stock_avant INT,
 stock_apres INT,
 promotion INT,
 jour_semaine STRING,
 livraison INT,
 montant DOUBLE
)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ','
TBLPROPERTIES ("skip.header.line.count"="1");
```

Livrables transmis au Groupe 7

Script `analyse.hql`, tables Hive, résultats CSV et comparaison Hive/MapReduce.

10 TP Groupe 7 – Spark et PySpark

Objectif

Reproduire et enrichir l'analyse avec les abstractions modernes de Spark.

Travail demandé

Charger HDFS dans un DataFrame PySpark, définir explicitement le schéma, nettoyer les données, reproduire les indicateurs Hive/MapReduce et vérifier leur égalité. Créer ensuite des variables pour le Machine Learning : heure, mois, week-end, montant brut, taux de remise, indicateurs catégoriels et agrégats historiques ne provoquant pas de fuite de données.

Comparer Python séquentiel, MapReduce, Hive et PySpark en termes de temps, expressivité, facilité de développement et passage à l'échelle.

Livrables transmis au Groupe 8

`transactions_features` en Parquet, script/notebook PySpark, dictionnaire des features et benchmark comparatif.

11 TP Groupe 8 – Pipeline Big Data et Machine Learning

Problème retenu

Construire un modèle de régression permettant d'estimer le montant d'une transaction à partir des informations disponibles avant ou au moment de la vente. Le groupe devra discuter explicitement les variables qui provoqueraient une fuite de cible.

Pipeline minimal

HDFS → PySpark → Spark SQL/Hive → Feature Engineering → Spark ML → Évaluation.

Travail demandé

1. reprendre exclusivement le dataset préparé par le Groupe 7 ;
2. effectuer un découpage train/test reproductible ;
3. préparer variables numériques et catégorielles avec un Pipeline Spark ML ;
4. entraîner au minimum une régression linéaire et un Random Forest Regressor ;
5. comparer les modèles avec MAE, RMSE et R^2 ;

6. sauvegarder le meilleur modèle selon une règle annoncée à l'avance ;
7. produire les prédictions et une synthèse de l'architecture complète.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \qquad RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}.$$

12 Livrable collectif final

L'ensemble de la classe remet un dépôt unique :

```
bigdata_project/
  data_dictionary/
  group1_python/
  group2_hdfs/
  group3_mapreduce_design/
  group4_streaming/
  group5_yarn/
  group6_hive/
  group7_spark/
  group8_ml/
  results/
  README.md
```

Le rapport final doit montrer la traçabilité des données et des résultats depuis l'ingestion jusqu'au modèle de Machine Learning.

13 Évaluation proposée

Critère	Pondération
Maîtrise scientifique et technique	20%
Démonstration	15%
TP et qualité du code	30%
Analyse et validation des résultats	20%
Transmission au groupe suivant	10%
Reproductibilité et documentation	5%

14 Consigne importante

Une valeur obtenue avec une technologie doit être contrôlée par rapport aux résultats antérieurs. Les divergences doivent être expliquées : types numériques, séparateur CSV, en-tête, valeurs manquantes, arrondis, doublons ou différences de logique analytique. La réussite du projet dépend donc autant de la continuité entre groupes que de l'utilisation correcte de Hadoop, Hive et Spark.